

Pipeline de Datos del Macroentorno Ecuatoriano: Limpieza, Modelo Relacional y Dashboard Analítico

Martin Emanuel Ruiz Sanchez Carrera de Computacion
 Universidad Tecnica Particular de Loja
 Loja, Ecuador
 meruiz22@utpl.edu.ec

Resumen—

Index Terms—

I. INTRODUCCION

El Tablero Macroentorno de la UTPL consolida indicadores economicos y laborales de nueve fuentes publicas del Ecuador. Su actualizacion es manual y su pipeline carece de documentacion reproducible. Cuando cambia un archivo fuente, el conocimiento para actualizarlo vive en personas, no en codigo.

El reto de Practicum 2.2 de 6to ciclo resuelve ese problema en siete semanas. El pipeline parte de los archivos crudos que entrega el equipo de RPA y termina en un dashboard con tres preguntas analiticas respondidas. El stack es Python, PostgreSQL y Power BI.

El dashboard responde tres preguntas concretas para la UTPL. P1 analiza la evolucion economica ecuatoriana de los ultimos 20 anos con datos del BCE. P2 identifica los sectores y provincias con mayor actividad economica y empleo usando VAB, ENEMDU y el Censo 2022. P3 cruza bachilleres por provincia (MINEDUC) con empresas activas (Supercias) para detectar zonas con demanda potencial de educacion superior; ese cruce alimenta directamente el Tablero de Segmentacion de Marketing de la UTPL.

Construir ese pipeline requiere competencias que el mercado demanda con urgencia. El Future of Jobs Report 2025 proyecta que la demanda de especialistas en Big Data crece mas del 100 % entre 2025 y 2030 [13]. La UTPL forma a esos especialistas con datos reales, fuentes publicas y decisiones tecnicas concretas.

El estado del arte responde cuatro preguntas vinculadas a los entregables del reto:

- **P1.** Que arquitectura integra fuentes heterogeneas de datos publicos en un pipeline reproducible.
- **P2.** Como se disena el modelo relacional antes de escribir codigo.
- **P3.** Que stack tecnico y practicas de limpieza son criticos para cargar fuentes heterogeneas correctamente.
- **P4.** Como se integra el pipeline con un proceso de automatizacion y que anticipa ese patron para 2025–2030.

II. MARCO CONCEPTUAL

Data Warehouse. Repositorio central de datos historicos estructurados, integrados desde multiples fuentes y optimizados

para consultas analiticas [6]. Transforma los datos antes de cargarlos (ETL) y mantiene esquemas fijos.

Data Lake. Almacen de datos en formato crudo sobre almacenamiento de objetos de bajo costo [2]. Acepta datos estructurados, semi-estructurados y no estructurados sin transformacion previa. Requiere metadatos activos para mantener la rastreabilidad de cada archivo.

Data Lakehouse. Arquitectura que une la flexibilidad del Data Lake con las garantias transaccionales del Data Warehouse en una sola plataforma [1]. Soporta cargas analiticas y de machine learning sin mover datos entre sistemas.

Arquitectura Medallon (Bronze–Silver–Gold). Patron de tres zonas de calidad progresiva dentro de un Lakehouse [3]. Bronze guarda los datos en su estado original e inmutable. Silver aplica limpieza, tipado y normalizacion. Gold materializa vistas o tablas derivadas listas para el dashboard. En el reto, Bronze recibe los archivos de RPA, Silver los almacena en PostgreSQL con doce tablas y FK correctas, y Gold expone cuatro vistas para Power BI.

ETL (Extract, Transform, Load). Proceso que extrae datos, los transforma en un motor intermedio y los carga ya limpios en el destino [6]. Es el patron clasico del Data Warehouse.

ELT (Extract, Load, Transform). Variante que carga los datos en crudo primero y transforma dentro del motor de destino [8]. El reto sigue ELT: cada modulo Python carga en PostgreSQL y las vistas Gold transforman ahi mismo.

Pipeline de datos. Secuencia automatizada de pasos que mueve y transforma datos desde las fuentes hasta el destino [10]. El pipeline del reto es reproducible: `pipeline.py` detecta archivos nuevos de RPA y los procesa sin intervencion manual.

Modelo Entidad-Relacion (ER). Representacion grafica de entidades, atributos y relaciones de un dominio [7]. El diagrama ER del reto define `dim_tiempo` y `dim_geografia` como dimensiones compartidas entre las nueve fuentes, y especifica las claves foraneas de cada tabla `fact_` antes de escribir codigo.

III. TRABAJOS RELACIONADOS

La Tabla I sintetiza los trabajos que fundamentan las decisiones tecnicas del reto.

Armbrust et al. [1] formalizaron el Lakehouse en CIDR 2021. Jain et al. [4] compararon Delta Lake, Hudi e Iceberg; Delta Lake lidera en velocidad de carga; Iceberg ofrece mayor interoperabilidad. Sawadogo y Darmont [2] confirman que

Cuadro I
TRABAJOS RELACIONADOS

Ref.	Aporte	Conexion directa con el reto
[1]	Formaliza el Lakehouse: storage y ACID	Bronze recibe archivos de RPA. Silver en PostgreSQL aplica ACID.
[2]	Sin linaje el repositorio se degrada	Cada modulo documenta sus decisiones de limpieza: nulos, tipos y deduplicacion.
[6]	Metodologia dimensional de 4 pasos	Define dim_tiempo, dim_geografia y las doce tablas Silver con FK.
[8]	ELT: cada fuente propietaria de su logica	bce.py, inec.py, supercias.py y mineduc.py encapsulan la limpieza de su fuente.
[5]	RPA optimiza ingestion; contratos criticos	El acuerdo de semana 4 fija subcarpeta, formato de nombre y canal de notificacion.
[7]	Grafos ER son el estandar de BD modernas	El tutor aprueba el diagrama ER en semana 1 (10 % evaluacion) antes de que el estudiante escriba codigo.
[12]	Parrafo interpretativo supera a la estetica	6to ciclo exige un parrafo de analisis ejecutivo por pagina del dashboard.
[11]	Preparacion de datos consume >70 % del tiempo	Las semanas 1 a 4 se dedican a limpieza y modelo. Power BI se conecta en semana 5.

documentar el linaje de cada archivo es lo que separa un Data Lake util de uno inutilizable. Kimball y Ross [6] formalizan la metodologia dimensional. Barret et al. [7] confirman que el diagrama ER sigue siendo la herramienta estandar para comunicar un diseno relacional antes de implementarlo. Machado et al. [8] describen el paso de ETL a ELT en el contexto Data Mesh: cada fuente es propietaria de su logica de limpieza. Bhardwaj et al. [5] demuestran que RPA escala el procesamiento de datos estructurados cuando los contratos de interfaz son precisos. Lai et al. [11] miden que la preparacion de datos consume mas del 70 % del tiempo en proyectos de BI. Tadakala et al. [12] demuestran que los dashboards con parrafo interpretativo por pagina superan en efectividad a los que priorizan la presentacion visual.

IV. HERRAMIENTAS Y STACK TECNICO

El reto define un stack de tres capas: Python transforma, PostgreSQL almacena y Power BI visualiza.

La Fig. 1 presenta el modelo ER. Se diseña y entrega, antes de escribir cualquier linea de codigo. El diagrama muestra las doce tablas con sus claves primarias y foraneas. dim_tiempo y dim_geografia se comparten entre las nueve fuentes. Las tablas de hechos (fact_macro_anual, fact_empleo, fact_indicadores_diarios y las de VAB, IEE, Supercias y MINEDUC) referencian esas dimensiones con FK.

La Tabla II detalla el rol de cada herramienta en el pipeline.

Python procesa cada fuente con un modulo independiente. inec.py aplica melt() para normalizar la estructura pivotada de ENEMDU. mineduc.py lee el AMIE con encoding=latin-1 y separador ;, y filtra por bachillerato




Figura 1. Modelo entidad-relacion de la capa Silver del reto. dim_tiempo y dim_geografia son dimensiones compartidas. Cada tabla fact_ referencia ambas con FK.

de ultimo grado. bce.py convierte las fechas del IEE con pd.to_datetime() y carga los cinco archivos del BCE. PostgreSQL recibe las doce tablas Silver con FK correctas y expone cuatro vistas Gold. Power BI conecta esas vistas via DirectQuery y construye las tres paginas del dashboard.

V. TENDENCIAS Y FUTURO

La Tabla III conecta cinco tendencias del campo de datos con los entregables especificos del reto.

La IA Generativa automatiza partes de la limpieza, pero la decision de como normalizar ENEMDU con melt() o como tratar el primer anio de variacion nula del PIB real requiere juicio del estudiante [13]. DataOps convierte la calidad de dato en parte del flujo de entrega [9]. El WEF proyecta mas del 100 % de crecimiento en demanda de especialistas en datos para 2030 [13]. Las habilidades que el reto desarrolla, diseno ER, limpieza de fuentes reales y storytelling analitico, son las que el mercado demanda.

VI. CONCLUSIONES

VI-A. *P1. Arquitectura para integrar fuentes heterogeneas en un pipeline reproducible*

La arquitectura Lakehouse con patron medallon Bronze-Silver-Gold organiza el pipeline en tres zonas de calidad

Cuadro II
STACK TECNICO DEL RETO DE 6TO CICLO

Herramienta	Capa	Uso en el reto	Tendencia 2025-26
Python + pandas	Bronze a Silver	bce.py, inec.py (con melt()), supercias.py, mineduc.py (latin-1)	polars supera a pandas en velocidad para tablas grandes
PostgreSQL 16	Silver + Gold	12 tablas Silver con FK. 4 vistas Gold. Vistas materializadas.	JSONB y particionamiento amplian su rol como capa Silver
Power BI Desktop	Gold a Dashboard	DirectQuery a PostgreSQL. Tres paginas: P1, P2 y P3.	Copilot IA genera parrafos de analisis en lenguaje natural
GitHub (privado)	Versiones	Modulos ETL, DDL SQL, README, acuerdo RPA-Datos	GitHub Actions valida esquemas en cada commit
draw.io	Diagrama	Arquitectura y ER (entregable semana 1)	Exportacion PDF/PNG para el repositorio

Cuadro III
TENDENCIAS 2025–2030 Y CONEXION CON EL RETO

Tendencia	Descripcion	Conexion con el reto
IA Generativa en pipelines	Automatiza limpieza e imputacion [11]	El reto entrena al estudiante en las decisiones que la IA asistira. El juicio sobre nulos y tipos de dato en ENEMDU no se delega.
DataOps continuo	Pruebas de calidad dentro del pipeline, no despues [9]	El 25 % de evaluacion en tablas Silver correctas replica este principio: la calidad es criterio de entrega.
Convergencia RPA-Datos	RPA ingesta fuentes sin API; el contrato de interfaz es el punto critico [5]	El acuerdo de semana 4 define subcarpeta, formato <code>fuentes_YYYYMMDD.xlsx</code> y canal de notificacion.
Data Mesh	Cada fuente es un producto de dato con propietario y SLA [8]	BCE, INEC, Supercias y MINEDUC son cuatro dominios independientes. Cada modulo Python es el propietario de su limpieza.
Dashboards con analisis ejecutivo	Parrafo interpretativo supera al visual puro [12]	6to ciclo exige un parrafo por pagina que conecte el dato con la estrategia de la UTPL.

progresiva [1], [3] (Fig. 2). Bronze recibe los archivos de las fuentes publicas sin modificarlos. Python los transforma y los carga en tablas relacionales en PostgreSQL. Las vistas Gold alimentan Power BI con indicadores listos para el dashboard. El repositorio GitHub con modulos versionados garantiza que cualquier miembro del equipo reproduce el resultado. Sawadogo y Darmont [2] confirman que documentar el linaje de cada decision de limpieza es lo que diferencia un repositorio util de uno inutilizable.




Figura 2. Arquitectura del pipeline del Macroentorno Ecuador. Almacena archivos crudos de RPA. Python transforma y carga en (PostgreSQL). Alimentan la visualización en Power BI.

VI-B. P2. Modelo relacional diseñado antes de escribir código

Kimball y Ross [6] proveen el marco de cuatro pasos: proceso de negocio, granularidad, dimensiones y metricas. El esquema resultante tiene dimensiones compartidas entre las fuentes y tablas de hechos con FK correctas (Fig. 1). Barret et al. [7] confirman que el diagrama ER comunica el diseño antes de que el código exista. El tutor aprueba ese diagrama al inicio del proyecto. Cada error detectado en el diagrama es un error que no aparece en la base de datos.

VI-C. P3. Stack tecnico y practicas de limpieza para fuentes heterogeneas

Python procesa cada fuente con un modulo independiente que encapsula su logica de limpieza: renombrado de columnas, tratamiento de nulos, conversion de tipos y normalizacion de fechas. PostgreSQL almacena las tablas relacionales y expone vistas Gold listas para DirectQuery. Power BI construye tres paginas analiticas que responden las preguntas P1, P2 y P3 del dashboard. Lai et al. [11] miden que mas del 70 % del tiempo de un proyecto de BI va a preparacion de datos. Dedicar la mayor parte del trabajo a la limpieza y al modelo antes de conectar la herramienta de visualizacion es la practica que distingue proyectos de BI exitosos de los que fallan en produccion.

VI-D. P4. Integracion con automatizacion y perspectiva 2025-2030

La integracion entre el pipeline de datos y un proceso de automatizacion requiere un contrato de interfaz preciso: nombre de carpeta, formato de archivo y canal de notificacion. Bhardwaj et al. [5] demuestran que la automatizacion escala cuando esos contratos son precisos. El pipeline detecta los archivos nuevos y los procesa sin intervencion manual (Fig. 2). Para 2030, el Data Mesh y DataOps consolidan un modelo donde cada fuente es un producto de dato con propietario y SLA [8]. El estudiante que termina este reto practica ese modelo con datos reales desde el primer dia.

REFERENCIAS

- [1] M. Armbrust, A. Ghodsi, R. Xin y M. Zaharia, "Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics," en *Proc. 11th CIDR*, 2021. https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf
- [2] P. N. Sawadogo y J. Darmont, "On data lake architectures and metadata management," *J. Intell. Inf. Syst.*, vol. 56, no. 1, pp. 97–120, 2021. <https://doi.org/10.1007/s10844-020-00608-7>
- [3] Databricks, "What is medallion lakehouse architecture?" *Microsoft Azure Docs*, 2024. <https://learn.microsoft.com/en-us/azure/databricks/lakehouse/medallion>
- [4] P. Jain, P. Kraft, C. Power, T. Das, I. Stoica y M. Zaharia, "Analyzing and comparing lakehouse storage systems," en *Proc. 13th CIDR*, 2023. <https://www.cidrdb.org/cidr2023/papers/p92-jain.pdf>
- [5] V. Bhardwaj, A. Noonina, S. Chaurasia, M. Kumar, A. Rashid y M. T. Ben Othman, "Optimizing structured data processing through robotic process automation," *J. Eur. Syst. Autom.*, vol. 57, no. 5, pp. 1523–1530, 2024. <https://doi.org/10.18280/jesa.570528>
- [6] R. Kimball y M. Ross, *The Data Warehouse Toolkit*, 3ra ed. Hoboken, NJ: John Wiley & Sons, 2013.
- [7] N. Barret et al., "Entity/Relationship graphs: Principled design, modeling, and data integrity management," *Proc. ACM Manag. Data*, vol. 3, no. 1, 2025. <https://doi.org/10.1145/3709690>
- [8] I. A. Machado, C. Costa y M. Y. Santos, "Data mesh: Concepts and principles of a paradigm shift in data architectures," *Procedia Comput. Sci.*, vol. 196, pp. 263–271, 2022. <https://doi.org/10.1016/j.procs.2021.12.033>
- [9] A. R. Munappy, D. I. Mattos, J. Bosch, H. H. Olsson y A. Dakkak, "From ad-hoc data analytics to DataOps," en *Proc. IEEE ICSSP*, 2021. <https://doi.org/10.1109/ICSSP52582.2021.00021>
- [10] J. Naso y C. Padden, *Data Platform Fundamentals*. Dagster Labs, 2024. <https://dagster.io/blog/data-platform-fundamentals>
- [11] E. Lai, Y. He y S. Chaudhuri, "Auto-Prep: Holistic prediction of data preparation steps for self-service BI," *Proc. VLDB Endow.*, vol. 14, no. 7, 2025. arXiv:2504.11627.
- [12] L. Tadakala et al., "Beyond visualization: Building decision intelligence through iterative dashboard refinement," arXiv:2510.27572, 2025. <https://arxiv.org/pdf/2510.27572>
- [13] World Economic Forum, *Future of Jobs Report 2025*. Ginebra: WEF, 2025. <https://www.weforum.org/publications/the-future-of-jobs-report-2025/>